

Desenvolvimento de Árvore-B em Memória Secundária

Trabalho de implementação e análise de desempenho

Caio Uehara Yuri Calzzani Igor Felipe

PPGCA — DCM

Algoritmos e Estruturas de Dados

Docente: Prof. Dr. José Augusto Baranauskas

Agenda

Decisões e Arquitetura

Demonstração

Análise Experimental

Discussão

Decisões e Arquitetura

Decisões de Implementação (Slide 2)

Armazenamento da raiz

Mantida de forma **dupla**:

- em memória, no atributo `rootID`;
- em disco, no registro 0 (cabeçalho).

O cabeçalho é reescrito em 4 momentos: *criação*, *split*, *colapso* da raiz e *carregamento*.

Reaproveitamento de nós — **sim**

- **Estrutura:** lista de livres (“lixeira”), topo no `A[1]` do cabeçalho, encadeada pelo `A[0]` de cada registro livre.
- **Como:** `freeNode()` empilha o nó removido; `allocateNode()` recicla antes de crescer o arquivo.

Armazenamento estritamente em memória secundária

Cada nó é um registro de **tamanho fixo** $(2M + 3) \cdot \text{sizeof}(\text{int})$, lido/escrito **um por vez** por *seek* + *struct* (sem cache de vários nós em RAM) — atende ao requisito do enunciado.

```
template <int M>
struct BTreeNode { int numKeys; int K[M+1]; int A[M+1]; };

file.seekg(id * sizeof(BTreeNode<M>), std::ios::beg); // 1 nó
file.read ((char*)&node, sizeof(BTreeNode<M>));      // 1 registro
```

Conferência: arquivo de $M=3/1000$ chaves = $35\,820$ bytes $\div$ 36 bytes-por-nó = 995 registros exatos.

Métodos Implementados (Slide 3)

BTree<M>

search, insert, split, remove,
removeRecursive, borrowFromLeft/Right,
mergeChildren, loadFromFile, getHeight.

BTreeNode

findIndex(key) localiza a chave ou o ponto de inserção.

DiskManager (contador de I/O)

incrementRead/Write,
getReadCount/WriteCount, resetCounters,
getFileSize.

Módulo Display

displayTree, displayLevelOrder, dumpFile,
displaySearchResult. (*lógica e visualização separadas.*)

Demonstração

Caso de uso em código: reaproveitamento de nós

A “lixeria” do Slide 2 são estes dois métodos (src/btree.h):

```
// Aloca um nó: recicla da lixeira antes de crescer o arquivo.
int allocateNode() {
    BTreeNode<M> hdr; readNode(0, hdr);
    if (reuseEnabled && hdr.A[1] != 0) {          // há nó livre?
        int id = hdr.A[1];                        // topo da lixeira
        BTreeNode<M> n; readNode(id, n);
        hdr.A[1] = n.A[0];                        // desempilha
        writeNode(0, hdr);
        return id;                               // reaproveita o registro
    }
    file.seekp(0, std::ios::end);                 // senão, cresce o .dat
    return (int)(file.tellp() / sizeof(BTreeNode<M>));
}
// Libera um nó: empilha-o na lixeira (encadeada pelo A[0]).
void freeNode(int id) {
    BTreeNode<M> hdr; readNode(0, hdr);
    BTreeNode<M> dead; dead.A[0] = hdr.A[1];      // aponta p/ topo antigo
    writeNode(id, dead);
    hdr.A[1] = id; writeNode(0, hdr);             // novo topo da lixeira
}
```


Caso de uso em código: *split* (o ponto mais difícil)

Quando um nó enche ($\text{numKeys} == M$), ele é dividido e a mediana sobe:

```
void split(std::vector<int>& path) {
    int mid = (M+1)/2, leftID = path.back(); path.pop_back();
    BTreeNode<M> L; readNode(leftID, L);
    int rightID = allocateNode(); BTreeNode<M> R;
    int promo = L.K[mid]; // mediana promovida
    R.A[0] = L.A[mid]; R.numKeys = M - mid;
    for (int k=1; k<=M-mid; k++){ R.K[k]=L.K[mid+k]; R.A[k]=L.A[mid+k]; }
    L.numKeys = mid - 1; // L fica com a metade inferior
    writeNode(leftID, L); writeNode(rightID, R);
    if (path.empty()) { // raiz dividida -> nova raiz
        /* aloca nova raiz com 'promo' e atualiza o cabeçalho (rec 0) */
    } else { // insere 'promo' no pai...
        /* ...e, se o pai encher, split(path) recursivo (cascata) */
    }
}
```

A interface interativa em ação

Saída **real** do ./main.exe ($M=3$; inseridas 30, 20, 40, 55, 10, 35, 50; opção 4 – *Imprimir árvore*):

```
=====
                        ARVORE B
=====
1. Inserir chave
2. Remover chave
3. Buscar chave
4. Imprimir arvore
5. Estatisticas de I/O
6. Dump bruto do arquivo .dat
0. Voltar / Sair
Escolha uma opcao:

+===== RESULTADO =====+
--- Arvore (indentada) ---
[30 40] (rec 3)
  [10 20] (rec 1)
  [35] (rec 2)
  [50 55] (rec 4)

--- Arvore (por nivel) ---
Nivel 0: [30 40] (rec 3)
Nivel 1: [10 20] (rec 1)  [35] (rec 2)  [50 55] (rec 4)
+=====+
```

Estado em disco: estatísticas e *dump* bruto

Contadores de I/O da sessão:

```
+===== RESULTADO =====+  
--- Estatísticas do Disco ---  
Leituras (I/O): 57  
Escritas (I/O): 16  
Tamanho do arq: 180 bytes  
+=====+
```

Registros físicos do .dat:

```
+===== RESULTADO =====+  
--- Dump bruto do .dat (4 registros, 144 bytes, sizeof(no)=36) ---  
raiz: rec 3  
rec 0 (cabecalho): numKeys=0 | A[0]=3  
rec 1: numKeys=2 | A[0]=0 K[1]=10 A[1]=0 K[2]=20 A[2]=0  
rec 2: numKeys=2 | A[0]=0 K[1]=40 A[1]=0 K[2]=55 A[2]=0  
rec 3: numKeys=1 | A[0]=1 K[1]=30 A[1]=2  
+=====+
```

O rec 0 é o cabeçalho: A[0] guarda a raiz (aqui rec 3) e A[1], o topo da lixeira. 1 registro = 1 nó (144 bytes ÷ 36 = 4 registros).

Compilação e execução: o Makefile

Todo o fluxo do projeto é automatizado por alvos do make:

`make` compila `main.exe` (alvo padrão, `g++ -std=c++17`).

`make run` garante `tmp/` e abre o `modo interativo`.

`make test` compila e roda os `27 testes` (`tests/test_btree.cpp`).

`make run_experiments` roda a bateria completa → `data/*.csv`.

`make graficos` gera as figuras da análise (`slides/img/*.png`).

`make sessions` captura os *prints* reais da interface (`slides/sessions/*.txt`).

`make slides-assets` = `graficos` + `sessions` (regenera o que o deck inclui).

`make slides` compila `slides/apresentacao.pdf` (`pdflatex`, 2 passadas).

`make clean` remove binários, `tmp/` e auxiliares do $\text{\LaTeX}$.

Análise Experimental

Análises Efetuadas (Slide 4)

Testes unitários

27 casos (11 search, 7 insert, 9 remove), cada um em processo filho (fork) para isolar *crashes*.

Desempenho — 70 execuções

- Ordens M : 3, 5, 10, 50, 100, 500, 1000
- Volumes: 10^3 , 10^4 , $5 \cdot 10^4$, 10^5 , 10^6
- Padrões: Sequencial e Aleatório

Além disso, um experimento de *churn* (insere $N \rightarrow$ remove $N/2 \rightarrow$ reinsere $N/2$) compara a ocupação do arquivo **com e sem** reaproveitamento de nós.

Como testamos: oráculo por *fixtures*

- Cada caso roda em um **processo filho** (fork): um *crash* (ex.: split com bug) vira um **único FAIL** em vez de abortar a suíte.
- **27 casos** cobrindo: search (presente/ausente/vazia), insert (sem split, split, *cascata*, $m=5$), remove (folha, *borrow*, *merge*, colapso da raiz, no-op).
- **Fixtures** em tests/fixtures/*.txt: árvores em texto legível (com comentários) $\Rightarrow$ fáceis de inspecionar e versionar.

Formato da fixture (search_tree.txt):

```
root 1
1  1  2  30 3          # rec1: A0=2 K1=30
      A1=3
2  1  4  20 5
3  1  6  40 7
4  2  0  10 0  15 0  # folha [10 15]
...
```

Linha: id numKeys A[0] (K[i] A[i])...

Fluxo de um caso: loadFromFile → operação → compareLogical

1. loadFromFile **materializa** a fixture (texto) no arquivo binário .dat — *before* e *after*.
2. A operação (insert/remove) roda no fork sobre o *before*; o destrutor faz *flush* antes do pai ler.
3. compareLogical compara o resultado com o *after*.

Comparação lógica: percorre as duas árvores em paralelo e confere *forma + chaves*, **ignorando** ids físicos e nós mortos da lixeira — um remove pode deixar o arquivo com layout diferente, mas a árvore é a mesma.

```
pid = fork();
if (pid == 0) {                                // filho
    BTree<M> t(actual);
    t.loadFromFile(before);
    op(t);                                     // insert/
        remove
    _exit(0);                                  // dtor: flush
}
waitpid(pid, &status, 0);
if (WIFSIGNALED(status)) // crashou?
    check(name, false, "crash");
bool ok = compareLogical<M>(
    actual, expected, msg);
check(name, ok, msg);
```


Métricas Utilizadas (Slide 5)

`M / numKeys / tipo` Ordem, nº de chaves e padrão (Seq/Rand).

`reads / writes / avg` Leituras e escritas de nós em disco e a *média por operação* (`readNode/writeNode`).

`tempo_cpu / tempo_io` Tempo de CPU *separado* do tempo gasto nas chamadas de I/O (`tempo_cpu = total - tempo_io`); como o `.dat` cabe na RAM, `tempo_io` reflete o *page cache* (ver slide de I/O real).

`bytes` Tamanho final do `.dat` (`getFileSize()`) — ocupação.

`altura` Nº de níveis da árvore (`getHeight()`, descendo 1 nó por vez).

Obs.: `avg_reads` inclui o acesso ao registro 0 (cabeçalho/lixreira) feito a cada alocação.

Tabela de Resultados (Slide 6)

Inserção sequencial — data/resultados_experimentos.csv

M	N	altura	avg_reads	$t_{cpu}(s)$	$t_{io}(s)$	bytes
3	10^3	9	10,95	0,002	0,009	35 820
3	10^5	16	17,69	0,23	1,20	3 599 820
3	10^6	19	20,95	2,67	14,18	35 999 784
100	10^6	4	3,80	1,12	3,49	16 571 296
1000	10^6	3	2,50	2,61	3,52	16 064 060

- $M \uparrow \Rightarrow$ altura $\downarrow$ e avg_reads $\downarrow$ (menos acessos a disco por operação).
- Para M pequeno, $t_{io} \gg t_{cpu}$ (operação limitada por I/O).

Impacto do Reuso na Ocupação (Slide 6)

Workload: insere $N \rightarrow$ remove $N/2 \rightarrow$ reinsere $N/2$ (Seq) — data/reuso_comparacao.csv

M	N	bytes <i>com</i> reuso	bytes <i>sem</i> reuso	economia
3	10^4	359 856	539 784	$\approx 33\%$
10	10^5	2 299 632	3 449 540	$\approx 33\%$
100	10^5	1 657 292	2 485 532	$\approx 33\%$


- Com reuso, a reinserção recicla os nós liberados; sem reuso, o arquivo cresce sempre $\Rightarrow \approx 1/3$ de economia de disco.

Perguntas do enunciado → onde respondemos

Pergunta experimental	Resposta
Como a ordem M afeta os acessos a disco?	fig. <i>reads</i> , tabela
Conjuntos de 10^3 a 10^6 , Seq e Aleatório	70 execuções (varredura)
Nº médio de acessos por operação	avg_reads, fig. <i>reads</i>
Ocupação do arquivo (com e <i>sem</i> reuso)	fig. <i>reuso</i> , fig. <i>ocupação</i>
Tempo de execução: CPU vs. I/O	fig. <i>trade-off</i>
Inserção Sequencial vs. Aleatória	fig. <i>reads/ocupação</i>
Altura da árvore vs. M e vs. N	fig. <i>altura</i>
Existe uma ordem M ótima?	fig. <i>trade-off</i> ($\sim M=100-500$)

Os gráficos a seguir são gerados de `data/resultados_experimentos.csv` por `analysis/gerar_graficos.py` (make graficos).


Acessos a disco $\times$ ordem M



$M \uparrow \Rightarrow$ menos leituras por operação; a partir de $M \approx 100$ estabiliza em $\sim 2-3$ acessos (árvore mais rasa).


Altura da árvore ($\times M$ e $\times N$)

Altura da árvore: cresce com N , encolhe com M




$\text{Altura} \propto \log_M N$: cresce devagar com N e cai bruscamente com M (de 19 níveis em $M=3$ para 3–4 em $M \geq 100$, $N=10^6$).

Trade-off CPU $\times$ I/O (em memória)




Tempos [servidos pelo page cache](#) (o .dat cabe na RAM): em memória, M pequeno faz mais acessos (mais syscalls/memcpy) e M grande gasta [CPU](#) (busca linear em nós grandes) — mínimo em $M \approx 100$.
[Sob I/O real](#) o quadro muda (próximo slide).

Cache de RAM × disco real: medindo o I/O honesto




O .dat de 10^6 chaves (11–36 MB) cabe na RAM $\Rightarrow$ o [page cache do SO](#) serve quase todo o I/O; o tempo_io “cacheado” mede *memória*, não a mecânica do disco (device é [NVMe](#), sem agulha). Limitando a RAM do processo por cgroup (`systemd-run -p MemoryHigh=8M`, opção 2) forçamos o dispositivo: só a inserção [aleatória](#) (baixa localidade, *working set* = árvore toda) paga I/O real ([até 16×](#)); a [sequencial](#) (espinha direita) quase não muda. [reads/bytes/altura](#) são [idênticos](#) entre os modos — a métrica lógica independe do cache.

Ocupação e padrão de inserção (Seq × Rand)



A inserção **aleatória** preenche melhor os nós (arquivo menor); a **sequencial** deixa nós meio-cheios após cada split.

Reuso de nós: ocupação *com* × *sem*



Workload de churn (insere N , remove $N/2$, reinsere $N/2$): reciclar nós liberados economiza $\approx 1/3$ de disco.

Discussão

Utilização de IA (Slide 7)

Usamos um assistente de IA como [apoio](#), sempre com validação humana e conferência contra os dados e o enunciado. Onde ajudou:

[Revisão de código](#) Revisão crítica que apontou casos de borda — destaque para a [falha silenciosa de I/O](#) quando `tmp/` não existia ($\rightarrow$ `throw` em `readNode/writeNode` e criação de `tmp/`).

[Geração de casos de teste](#) Sugestão de *fixtures* e cenários (split em cascata, *borrow/merge*, colapso da raiz, no-ops) que ampliaram a cobertura para os 27 casos.

[Comentários e documentação](#) Apoio na redação de comentários do código, do README e dos cabeçalhos das funções.

[Revisão dos slides](#) Conferência da aderência ao modelo do enunciado e da consistência dos números com os CSVs.

Decisões de projeto, implementação e análise permaneceram do grupo; a IA acelerou estudo, revisão e redação.

Dificuldades, Vantagens e Desvantagens (Slide 8)

Dificuldades

- Ponteiros no split/merge
- Persistência do cabeçalho
- `removeRecursive` (todos os casos)
- Nós órfãos / controle de I/O

Vantagens

- Altura logarítmica
- Poucos acessos a disco/op.
- Naturalmente balanceada
- Busca ordenada / por intervalo (eficiente na variante B+)

Desvantagens (vs. outras)

- vs. **AVL/BST**: mais complexa, custo de split/merge
- vs. **hash**: $O(1)$ ponto, mas [sem ordem/intervalo](#) e degrada em disco

Aplicações Práticas (Slide 9)

Bancos de dados relacionais MySQL InnoDB e PostgreSQL usam Árvore B+ nos índices para localizar registros em $O(\log n)$ acessos a disco.

Sistemas de arquivos NTFS, APFS e ext4 usam Árvore B/B+ para diretórios e localização de blocos.

NoSQL / embarcado SQLite e Berkeley DB (B/B+). *LevelDB* e *RocksDB* usam **LSM-tree** — alternativa à Árvore B otimizada para escrita intensiva.

Aplicação que adotariamos: o índice de um SGBD próprio — exatamente o cenário deste trabalho (registros de tamanho fixo, 1 nó por acesso).

Conclusão e Referências (Slide 10)

- **Ordem M reduz acessos e altura:** para 10^6 chaves, avg_reads cai de 20,95 ($M=3$) para 2,50 ($M=1000$) e a altura de 19 para 3 níveis.
- **CPU vs. I/O (com a ressalva do cache):** os tempos da bateria são servidos pelo page cache (o .dat cabe na RAM; device NVMe), não pela mecânica do disco. Forçando I/O real por cgroup, só a inserção aleatória (baixa localidade) paga disco — a contagem de acessos (métrica lógica, independente da máquina) continua sendo o resultado robusto.
- **Reuso de nós economiza $\approx 33\%$ de ocupação do arquivo.**
- **Robustez:** contador de I/O agora falha alto (throw se o arquivo não abre); tmp/ é criado antes de medir.
- **Conformidade:** I/O estritamente 1 nó por vez (1 seek + 1 struct).

Referências: CORMEN et al. *Introduction to Algorithms*, 4. ed., MIT Press, 2022 (Cap. 18). COMER, D. "The Ubiquitous B-Tree". *ACM Comp. Surveys*, 1979. KNUTH, D. *TAOCP*, v.3.

Obrigado!

Caio Uehara • Yuri Calzzani • Igor Felipe